

A Lógica e a História do Fator 1,5 de Tukey

Por que 1,5 e não 2 ou 1? De onde John Tukey tirou esse número em 1977?

Marco Antonio Lima de Castro

Resumo

O texto explora a fundamentação histórica e matemática por trás do fator 1,5 de Tukey, utilizado para identificar valores atípicos em boxplots. A constante foi estabelecida em 1977 por John Tukey devido à facilidade do cálculo mental em uma era pré-computacional e à necessidade de métricas resistentes a anomalias. Além do pragmatismo empírico nos Bell Labs, o texto detalha a conexão desse método com a Distribuição Normal e a probabilidade acumulada sob a curva de Gauss. São apresentadas resoluções matemáticas complexas, incluindo integrais de Gauss e aproximações para a função quantil, que validam a eficácia do fator. Em suma, o conteúdo demonstra como uma convenção prática de análise exploratória se equilibra entre a simplicidade aritmética e o rigor estatístico.

1 Introdução

Na década de 1970 - e mais especificamente em **1977**, ano em que John W. Tukey publicou sua obra clássica *Exploratory Data Analysis* (EDA) - o cenário da estatística e da computação era radicalmente diferente do atual.

A escolha do fator **1,5** para as cercas do *boxplot* foi moldada por cinco motivos históricos e filosóficos que refletem a época:

1.1 A Era do Lápis, Papel e Cálculo Mental

Na década de 70, computadores eram recursos escassos, caros e inacessíveis para o trabalho diário de estudantes e pesquisadores. A análise estatística era feita predominantemente à mão, em folhas de papel milimetrado e com o auxílio de réguas de cálculo ou calculadoras mecânicas simples.

Tukey queria uma ferramenta visual prática que qualquer pessoa pudesse desenhar rapidamente. A operação por trás do fator **1,5** tem uma propriedade aritmética simples:

Multiplicar por 1,5 é equivalente a pegar um valor e somar com a sua própria metade.

Para quem estava calculando no papel, achar a largura da caixa (IQR), dividir esse valor por 2 e somá-lo à borda da caixa era uma conta mental quase instantânea, dispensando divisões complexas ou tabelas de distribuição.

1.2 A Filosofia da "Análise Exploratória de Dados" (EDA)

Antes de Tukey, a estatística era dominada pelo paradigma confirmatório (testes de hipóteses rigorosos, pressupostos de normalidade estritos e cálculo de médias). Tukey introduziu a atitude do **estatístico como um detetive**:

- O objetivo do *boxplot* não era emitir um "veredito matemático final" sobre um ponto ser inválido, mas sim **chamar a atenção visual** do analista para pontos que mereciam investigação.
- Ele precisava de uma régua empírica rápida (*rule of thumb*) que separasse o comportamento rotineiro dos dados daqueles valores que exigiam um olhar mais atento.

1.3 A Busca por "Estatísticas Resistentes"(Robustez)

A estatística clássica usava a média e o desvio-padrão para identificar anomalias (como a regra dos 3σ). O grande problema prático que Tukey e seus colegas do *Bell Labs* enfrentavam era que **um único outlier extremo inflava o desvio-padrão e deslocava a média**, fazendo com que o próprio teste falhasse em detectar o problema.

Tukey adotou os **quartis e a amplitude interquartílica (IQR)** porque são métricas não paramétricas e **resistentes a contaminações**. O fator 1,5 funcionava como uma ponte prática que imitava a sensibilidade do filtro de 3 desvios-padrão da curva normal, mas sem sofrer da instabilidade da média e do desvio-padrão.

1.4 O Teste Empírico nos Laboratórios Bell

Ao testar a ferramenta com múltiplos conjuntos de dados reais nos Laboratórios Bell, Tukey observou o comportamento de diferentes multiplicadores:

- **Se usasse 1,0:** O gráfico gerava "falsos alarmes" em quase toda amostra regular, poluindo o desenho com pontos que não tinham nada de especial.
- **Se usasse 2,0 ou 3,0:** A caixa ficava permissiva demais, escondendo anomalias moderadas que deveriam ser investigadas.

O fator **1,5** surgiu empiricamente como o ponto de equilíbrio ("*Goldilocks zone*") — nem rígido demais a ponto de causar paranoia, nem largo demais a ponto de cegar o pesquisador. Para valores verdadeiramente aberrantes, Tukey sugeriu o multiplicador **3,0** (que ele chamou de limite para *outliers* extremos).

1.5 Pragmatismo Engenheiresco vs. Dogma

John Tukey era engenheiro de formação e topógrafo antes de se tornar um dos maiores estatísticos do século XX. Ele enfatizava frequentemente que o **1,5 não era uma constante mágica universal ou uma lei da natureza**, mas sim uma **convenção de trabalho** conveniente e eficaz.

Quando questionado por colegas teóricos sobre o motivo exato de ter escolhido 1,5 em vez de outro número decimal complexo, a resposta famosa atribuída à tradição de Tukey era simples e pragmática: "*1,0 era pouco demais e 2,0 era demais.*"

2 A Conexão com a Distribuição Normal

2.1 Sob a hipótese de normalidade

Sob a hipótese de normalidade $X \sim \mathcal{N}(\mu, \sigma^2)$, onde:

- μ é a média populacional:
 - Medida de tendência central que indica o ponto de equilíbrio e centro de simetria da curva normal.
 - Graficamente: localiza o pico da curva em forma de sino. Na distribuição normal, a média (μ) coincide exatamente com a mediana e a moda.
- σ^2 é a variância populacional:
 - Média dos **desvios quadráticos** em relação à média populacional (μ).
 - Mede a variabilidade total do processo. Como sua unidade fica elevada ao quadrado, ela é usada principalmente para cálculos algébricos, enquanto o desvio padrão (σ) é usado para interpretar o gráfico.

DISTRIBUIÇÃO NORMAL: CONCEITO VISUAL (Curva de Gauss)




Figura 1: Distribuição Normal - Conceito Visual

2.2 A Função de Distribuição Acumulada (FDA) da Normal Padrão

A **Função de Distribuição Acumulada (FDA)** da **Normal Padrão** $Z \sim \mathcal{N}(0, 1)$ é denotada universalmente pela letra grega $\Phi(z)$. Ela calcula a probabilidade acumulada de uma variável aleatória normal assumir um valor menor ou igual a um determinado escore z , ou seja, $P(Z \leq z)$.

A densidade de probabilidade da distribuição normal padrão é:

$$\varphi(t) = \frac{1}{\sqrt{2\pi}} e^{-\frac{t^2}{2}} \quad (1)$$

A FDA é obtida integrando essa densidade desde o extremo esquerdo até o ponto z :

$$\Phi(z) = P(Z \leq z) = \int_{-\infty}^z \frac{1}{\sqrt{2\pi}} e^{-\frac{t^2}{2}} dt \quad (2)$$




Figura 2: Função de Distribuição Acumulada (FDA)

2.3 Entendendo o Conceito de Áreas

A área total sob toda a curva de Gauss (de $t = -\infty$ a $t = +\infty$) é definida como 1,0 (o equivalente a 100%). Como a distribuição normal é perfeitamente simétrica em relação ao centro ($z = 0$):

- A metade esquerda (de $-\infty$ até 0) contém metade da área total: 0,5 (50%).
- A metade direita (de 0 até $+\infty$) contém a outra metade da área total: 0,5 (50%).

Assim, $\Phi(0) = 0,5$. Para valores maiores:

$$\Phi(z) = 0,5 + \text{área entre 0 e } z \quad (3)$$

Exemplos práticos:

- Para $z = 1,15$: a área acumulada é $0,5 + 0,3749 = 0,8749$ (87,49%).
- Para $z = 3,00$: a área acumulada é $0,5 + 0,4987 = 0,9987$ (99,87%).

O Ponto Crucial: O valor 1,0 não é atingido em $z = 1$ nem em $z = 3$. Ele é a assíntota limite quando z tende ao infinito positivo ($z \rightarrow +\infty$).

2.4 Resolução Matemática das Integrais

Parte A: Provar que a Área Total vale 1,0 (quando $z \rightarrow +\infty$)

Queremos resolver a integral imprópria de toda a curva. Para resolver a integral de Gauss $I = \int_{-\infty}^{+\infty} e^{-\frac{t^2}{2}} dt$, elevamos a expressão ao quadrado e passamos para coordenadas polares ($x = r \cos \theta$, $y = r \sin \theta$, $dx dy = r dr d\theta$):

$$I^2 = \left(\int_{-\infty}^{+\infty} e^{-\frac{x^2}{2}} dx \right) \left(\int_{-\infty}^{+\infty} e^{-\frac{y^2}{2}} dy \right) = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} e^{-\frac{x^2+y^2}{2}} dx dy \quad (4)$$

Em coordenadas polares:

$$I^2 = \int_0^{2\pi} d\theta \int_0^{+\infty} r e^{-\frac{r^2}{2}} dr = 2\pi \cdot 1 = 2\pi \implies I = \sqrt{2\pi} \quad (5)$$

Substituindo na integral da probabilidade total:

$$I_{\text{total}} = \frac{1}{\sqrt{2\pi}} \cdot \sqrt{2\pi} = 1,0 \quad (6)$$

Parte B: Provar que $\Phi(0) = 0,5$

Como a função $g(t) = e^{-\frac{t^2}{2}}$ é par (simétrica em relação ao eixo $t = 0$), a integral da metade esquerda é exatamente metade da integral total:

$$\Phi(0) = \frac{1}{\sqrt{2\pi}} \frac{\sqrt{2\pi}}{2} = 0,5 \quad (7)$$

3 A Função Quantil Inversa (Φ^{-1}) e as Separatrizes

A função inversa $\Phi^{-1}(p)$ (conhecida como **função quantil** ou *probit*) faz o caminho oposto: dada uma probabilidade acumulada $p \in (0, 1)$, ela determina qual é o escore z correspondente.

Ela responde à pergunta: "Qual é o escore padronizado z tal que a probabilidade acumulada à sua esquerda seja exatamente p ?"

Esta função estabelece a ponte analítica entre a curva normal e os quartis:

- **1º Quartil (Q_1 ou P_{25}):** Acumula 25% da área, $z_1 = \Phi^{-1}(0,25) \approx -0,6745$.
- **Mediana / 2º Quartil (Q_2 ou P_{50}):** Acumula 50% da área, $z_2 = \Phi^{-1}(0,50) = 0$.
- **3º Quartil (Q_3 ou P_{75}):** Acumula 75% da área, $z_3 = \Phi^{-1}(0,75) \approx +0,6745$.




Figura 3: Função Quantil Inversa (Φ^{-1})

A função inversa não possui uma expressão algébrica elementar fechada. Softwares utilizam aproximações racionais de altíssima precisão. Uma aproximação clássica de Winitzki usa a Função de Erro Inversa (erf^{-1}).

3.1 Cálculo Passo a Passo para z_3 e z_1

Consultando a Tabela da Normal Padrão, buscamos a probabilidade de 0,7500.

- Linha 0,6, Coluna 0,07: 0,7486
- Linha 0,6, Coluna 0,08: 0,7517

Aplicando interpolação linear:

$$z_3 = 0,67 + \left(\frac{0,7500 - 0,7486}{0,7517 - 0,7486} \right) \cdot (0,01) \approx 0,6745 \quad (8)$$

Leitura Inversa na Tabela da Normal Padrão $\Phi(z)$ — Localização dos Quartis Q_1 e Q_3
Demonstração da busca "de trás para frente": Encontrando o escore z no cabeçalho a partir da probabilidade p no miolo

• Para o 1º Quartil ($Q_1 = 25\%$): Buscamos $p = 0,2500$ no miolo negativo. Está entre 0,2514 ($z = -0,67$) e 0,2483 ($z = -0,68$) $\rightarrow z_1 = -0,6745$
 • Para o 3º Quartil ($Q_3 = 75\%$): Buscamos $p = 0,7500$ no miolo positivo. Está entre 0,7486 ($z = +0,67$) e 0,7517 ($z = +0,68$) $\rightarrow z_3 = +0,6745$

Escore Negativo ($z \leq 0$) — Busca de Q_1 ($p = 0,2500$)

z	.00	.01	.02	.03	.04	.05	.06	.07	.08	.09
-0.0	0.5200	0.4990	0.4793	0.4600	0.4402	0.4202	0.4000	0.3799	0.3599	0.3399
-0.1	0.4602	0.4394	0.4189	0.3988	0.3789	0.3591	0.3394	0.3198	0.2999	0.2799
-0.2	0.4207	0.3989	0.3774	0.3561	0.3351	0.3143	0.2936	0.2730	0.2526	0.2323
-0.3	0.3821	0.3599	0.3379	0.3161	0.2944	0.2729	0.2514	0.2300	0.2088	0.1877
-0.4	0.3446	0.3219	0.2995	0.2773	0.2553	0.2334	0.2116	0.1899	0.1683	0.1468
-0.5	0.3085	0.2853	0.2625	0.2400	0.2177	0.1956	0.1736	0.1517	0.1299	0.1082
-0.6	0.2743	0.2509	0.2279	0.2052	0.1827	0.1603	0.1380	0.1158	0.0937	0.0717
-0.7	0.2420	0.2189	0.1961	0.1735	0.1511	0.1288	0.1065	0.0843	0.0621	0.0400
-0.8	0.2118	0.1889	0.1661	0.1435	0.1211	0.0988	0.0765	0.0543	0.0321	0.0100
-0.9	0.1841	0.1614	0.1388	0.1162	0.0937	0.0713	0.0489	0.0266	0.0043	0.0000
-1.0	0.1587	0.1359	0.1133	0.0907	0.0683	0.0458	0.0234	0.0011	0.0000	0.0000
-1.1	0.1357	0.1130	0.0904	0.0678	0.0452	0.0227	0.0003	0.0000	0.0000	0.0000
-1.2	0.1151	0.0924	0.0698	0.0472	0.0246	0.0021	0.0000	0.0000	0.0000	0.0000
-1.3	0.0968	0.0741	0.0515	0.0289	0.0063	0.0000	0.0000	0.0000	0.0000	0.0000
-1.4	0.0808	0.0581	0.0355	0.0129	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000
-1.5	0.0669	0.0442	0.0216	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000
-1.6	0.0548	0.0321	0.0095	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000
-1.7	0.0446	0.0219	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000
-1.8	0.0359	0.0132	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000
-1.9	0.0287	0.0060	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000
-2.0	0.0228	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000
-2.1	0.0179	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000
-2.2	0.0139	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000
-2.3	0.0107	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000
-2.4	0.0082	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000
-2.5	0.0062	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000
-2.6	0.0047	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000
-2.7	0.0035	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000
-2.8	0.0026	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000
-2.9	0.0019	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000
-3.0	0.0013	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000

Escore Positivo ($z \geq 0$) — Busca de Q_3 ($p = 0,7500$)

z	.00	.01	.02	.03	.04	.05	.06	.07	.08	.09
0.0	0.5200	0.5490	0.5780	0.6060	0.6330	0.6590	0.6840	0.7080	0.7310	0.7530
+0.1	0.5198	0.5488	0.5778	0.6058	0.6328	0.6588	0.6838	0.7078	0.7308	0.7528
+0.2	0.5199	0.5489	0.5779	0.6059	0.6329	0.6589	0.6839	0.7079	0.7309	0.7529
+0.3	0.5179	0.5469	0.5759	0.6039	0.6309	0.6569	0.6819	0.7059	0.7289	0.7519
+0.4	0.5179	0.5469	0.5759	0.6039	0.6309	0.6569	0.6819	0.7059	0.7289	0.7519
+0.5	0.5179	0.5469	0.5759	0.6039	0.6309	0.6569	0.6819	0.7059	0.7289	0.7519
+0.6	0.5179	0.5469	0.5759	0.6039	0.6309	0.6569	0.6819	0.7059	0.7289	0.7519
+0.7	0.5179	0.5469	0.5759	0.6039	0.6309	0.6569	0.6819	0.7059	0.7289	0.7519
+0.8	0.5179	0.5469	0.5759	0.6039	0.6309	0.6569	0.6819	0.7059	0.7289	0.7519
+0.9	0.5179	0.5469	0.5759	0.6039	0.6309	0.6569	0.6819	0.7059	0.7289	0.7519
+1.0	0.5179	0.5469	0.5759	0.6039	0.6309	0.6569	0.6819	0.7059	0.7289	0.7519
+1.1	0.5179	0.5469	0.5759	0.6039	0.6309	0.6569	0.6819	0.7059	0.7289	0.7519
+1.2	0.5179	0.5469	0.5759	0.6039	0.6309	0.6569	0.6819	0.7059	0.7289	0.7519
+1.3	0.5179	0.5469	0.5759	0.6039	0.6309	0.6569	0.6819	0.7059	0.7289	0.7519
+1.4	0.5179	0.5469	0.5759	0.6039	0.6309	0.6569	0.6819	0.7059	0.7289	0.7519
+1.5	0.5179	0.5469	0.5759	0.6039	0.6309	0.6569	0.6819	0.7059	0.7289	0.7519
+1.6	0.5179	0.5469	0.5759	0.6039	0.6309	0.6569	0.6819	0.7059	0.7289	0.7519
+1.7	0.5179	0.5469	0.5759	0.6039	0.6309	0.6569	0.6819	0.7059	0.7289	0.7519
+1.8	0.5179	0.5469	0.5759	0.6039	0.6309	0.6569	0.6819	0.7059	0.7289	0.7519
+1.9	0.5179	0.5469	0.5759	0.6039	0.6309	0.6569	0.6819	0.7059	0.7289	0.7519
+2.0	0.5179	0.5469	0.5759	0.6039	0.6309	0.6569	0.6819	0.7059	0.7289	0.7519
+2.1	0.5179	0.5469	0.5759	0.6039	0.6309	0.6569	0.6819	0.7059	0.7289	0.7519
+2.2	0.5179	0.5469	0.5759	0.6039	0.6309	0.6569	0.6819	0.7059	0.7289	0.7519
+2.3	0.5179	0.5469	0.5759	0.6039	0.6309	0.6569	0.6819	0.7059	0.7289	0.7519
+2.4	0.5179	0.5469	0.5759	0.6039	0.6309	0.6569	0.6819	0.7059	0.7289	0.7519
+2.5	0.5179	0.5469	0.5759	0.6039	0.6309	0.6569	0.6819	0.7059	0.7289	0.7519
+2.6	0.5179	0.5469	0.5759	0.6039	0.6309	0.6569	0.6819	0.7059	0.7289	0.7519
+2.7	0.5179	0.5469	0.5759	0.6039	0.6309	0.6569	0.6819	0.7059	0.7289	0.7519
+2.8	0.5179	0.5469	0.5759	0.6039	0.6309	0.6569	0.6819	0.7059	0.7289	0.7519
+2.9	0.5179	0.5469	0.5759	0.6039	0.6309	0.6569	0.6819	0.7059	0.7289	0.7519
+3.0	0.5179	0.5469	0.5759	0.6039	0.6309	0.6569	0.6819	0.7059	0.7289	0.7519

Figura 4: Tabela da Normal Padrão

4 Aplicação no Boxplot e na Regra de Tukey

A FDA da Normal Padrão permite demonstrar a fundamentação matemática:

1. **Amplitude Interquartilica (IQR):** $IQR = Q_3 - Q_1 = 0,6745\sigma - (-0,6745\sigma) = 1,3490\sigma$.
2. **Determinação da Cerca Superior ($1,5 \cdot IQR$):**

$$\text{Cerca Superior} = Q_3 + 1,5 \cdot IQR = 0,6745\sigma + 1,5(1,3490\sigma) = 2,698\sigma \approx 2,7\sigma \quad (9)$$

3. **Cálculo da Probabilidade de Cauda:** Usando a FDA, a probabilidade de ultrapassar $\pm 2,7\sigma$ por acaso é $P(|Z| > 2,7) = 2 \cdot (1 - \Phi(2,7)) \approx 0,0070$ (ou 0,70%).

Aplicação na Análise do Boxplot e na Regra de Tukey (1,5 IQR)




Figura 5: Aplicação na Regra de Tukey

A regra de Tukey ($1,5 \times IQR$) é, portanto, uma excelente aproximação robusta (não-paramétrica) para o clássico limite de 3σ da distribuição normal, encontrando o "Ponto ótimo de sensibilidade" que evita o excesso de alarmes falsos sem depender de médias, que são sensíveis a outliers.