

Medidas Separatrizes, Boxplot e a Origem do Fator 1,5

Roteiro Técnico e Demonstrações Analíticas

Marco Antonio Lima de Castro

1 A Provocação: A Mediana e o Mapa das Separatrizes

O estudo das separatrizes nasce de uma provocação natural sobre a **Mediana**. Se a Mediana divide o nosso rol de dados perfeitamente ao meio (50% abaixo e 50% acima), o que aconteceria se continuássemos dividindo esses subconjuntos em partes iguais?

Ao fatiar a distribuição de frequências, criamos pontos de corte que mapeiam a dispersão e a concentração dos dados, permitindo uma análise exploratória robusta. O mapa a seguir ilustra a visão geral dessas quebras:




Figura 1: Mapa visual dividindo a amostra em Quartis, Decis e Percentis.

2 Quartis e a Base do Diagrama de Caixa

A divisão mais clássica após a mediana é o particionamento em **Quartis** (Q_1, Q_2, Q_3), que fracionam o conjunto em 4 partes de 25%. O intervalo entre o primeiro quartil (Q_1) e o terceiro quartil (Q_3) engloba os 50% centrais da amostra, sendo a métrica fundamental (Amplitude Interquartilica - IQR) para a construção do Boxplot.




Figura 2: Guia de Quartis e a Anatomia Clássica do Boxplot.

3 Decis

Quando a necessidade de granularidade aumenta, podemos fatiar os dados em 10 partes iguais de 10%, obtendo os **Decis** (D_1 a D_9). O quinto decil (D_5) equivale perfeitamente à Mediana e ao Segundo Quartil (Q_2).




Figura 3: A lógica de divisão e distribuição dos Decis.

4 Percentis

A divisão em 100 partes gera os **Percentis** (P_1 a P_{99}). Como representam a máxima granularidade descritiva em partições percentuais, eles são amplamente utilizados em

tabelas de crescimento, notas de exames padronizados e métricas de desempenho. O quinquagésimo percentil (P_{50}) equivale à Mediana, ao Q_2 e ao D_5 .




Figura 4: A lógica do Percentil explicada visualmente.

5 O Cálculo de Separatrizes: Rol Ordenado vs. Tabela Simples vs. Interpolação

O cálculo de qualquer separatriz apresenta nuances fundamentais dependendo da forma como os dados estão organizados.

5.1 Dados não agrupados (Rol Ordenado) e o Efeito de Tamanho da Amostra

Quando temos a amostra bruta, a determinação de um quartil ou percentil é um processo de contagem posicional. A posição de uma separatriz S em uma amostra de tamanho n possui duas abordagens matemáticas que se tornam equivalentes em grandes amostras:

$$\text{Método Clássico: } Pos = \frac{k \cdot (n + 1)}{D} \quad \text{versus} \quad \text{Método Simplificado: } Pos = \frac{k \cdot n}{D} \quad (1)$$

Onde $D \in \{4, 10, 100\}$ representa o divisor para Quartis, Decis e Percentis. É imperativo compreender a discrepância gerada pelo fator $(n + 1)$, observável nos cenários abaixo:

Cenário A: Amostra Pequena ($n = 5$)

Considere o rol ordenado: $[10, 20, 30, 40, 50]$. Analisando os Quartis ($D = 4$):

- **Método Clássico ($n + 1$):** A mediana (Q_2 , $k = 2$) retorna $Pos = 2 \cdot \frac{5+1}{4} = 3,0$. O valor exato é o 3º termo: **30,0**.
- **Método Simplificado (n):** A mediana (Q_2) retorna $Pos = 2 \cdot \frac{5}{4} = 2,5$. A média entre o 2º e o 3º termo é **25,0**.

Em $n = 5$, o método simplificado desvia o centro da amostra em 16,7%. O termo $+1$ é indispensável para garantir que o corte posicional coincida perfeitamente com a mediana real do rol.

Cenário B: Amostra Grande ($n = 100$)

Considere um rol com elementos contínuos de 1 a 100 ($[1, 2, \dots, 100]$):

- **Método Clássico:** Q_1 ($k = 1$) retorna $Pos = \frac{101}{4} = 25,25$.
- **Método Simplificado:** Q_1 retorna $Pos = \frac{100}{4} = 25,00$.

Em $n = 100$, a divergência é de meras 0,25 unidades (uma variação quase nula sobre a escala total).

Conclusão Prática: Em amostras pequenas, o termo $+1$ (método inclusivo) é matematicamente vital para evitar distorções no fatiamento posicional. Em *Big Data* ou amostras estatisticamente significantes, o $+1$ se dilui, permitindo o uso da fórmula simplificada por ser computacionalmente menos dispendiosa.

5.2 Dados Agrupados em Tabelas Simples (Variáveis Discretas)

Quando a variável é discreta e os dados assumem poucos valores que se repetem com alta frequência (ex: número de filhos), organizá-los em um rol contínuo extenso torna-se contraproducente. Nesses casos, utilizamos uma **tabela simples com frequências exatas para valores únicos**.

O caminho de cálculo neste cenário é uma transição elegante entre a contagem manual e a estatística de agrupamento. A lógica consiste em:

1. Calcular a posição teórica (geralmente $Pos = \frac{k \cdot (n+1)}{D}$ ou $Pos = \frac{k \cdot n}{D}$).
2. Utilizar a coluna de **Frequência Acumulada** (F_{ac}) para realizar uma **varredura vertical**.

A separatriz será o primeiro valor da variável (coluna x_i) cuja frequência acumulada iguale ou supere a posição calculada. Neste cenário, não há necessidade de interpolação analítica (salvo quando a posição cai no intervalo exato de salto entre duas frequências acumuladas), pois a variável é discreta.

5.3 Dados Agrupados em Classes e a Fórmula da Interpolação

Quando os dados estão agrupados em tabelas de frequência contínua, perdemos a identidade individual de cada elemento. As separatrizes devem ser estimadas assumindo que os dados se distribuem de maneira uniforme dentro de cada classe.

A fórmula clássica deriva diretamente da semelhança de triângulos na ogiva (polígono de frequências acumuladas), montando a seguinte interpolação linear:

$$S = l_i + \left(\frac{\frac{k \cdot n}{D} - F_{ant}}{f_i} \right) \cdot h \quad (2)$$

Onde:

- l_i : limite inferior da classe que contém a separatriz.

- $\frac{k \cdot n}{D}$: posição teórica buscada ($D = 4$ para quartis, $D = 10$ para decis, $D = 100$ para percentis).
- F_{ant} : frequência acumulada da classe anterior.
- f_i : frequência simples da classe da separatriz.
- h : amplitude do intervalo de classe.

5.4 A Discrepância de Abordagens (MVP)

É crucial destacar que o cálculo via Rol Ordenado ou Tabela Simples retornará valores exatos baseados em pontos reais da amostra, enquanto a Interpolação Linear em Classes retornará estimativas contínuas. Essa diferença metodológica gera uma **leve discrepância matemática** nos resultados práticos, fenômeno claramente ilustrado no painel interativo (MVP) em sala de aula. Quanto maior a amplitude das classes (h) e menor a uniformidade real dos dados, maior será a discrepância da interpolação em relação aos dados não agrupados.

6 A Dedução Analítica do Fator de Tukey (1,5)

Uma das maiores curiosidades no estudo da Estatística Descritiva é a escolha do multiplicador 1,5 na fórmula das cercas do Boxplot de John Tukey. Esta seção demonstra de forma sucinta como esse valor se conecta com a distribuição Normal Padrão $Z \sim \mathcal{N}(0, 1)$, aproximando-se da regra clássica dos 3σ .

Nota de Aprofundamento: Para uma explanação detalhada contemplando o contexto histórico (limitações de cálculo mental nos Laboratórios Bell) e as demonstrações matemáticas completas (incluindo resolução de integrais polares de Gauss e aproximações da Função Quantil Inversa), **consulte o documento complementar:** “A Lógica e a História do Fator 1,5 de Tukey” (ver arquivo `fator_tukey.pdf`).

6.1 Nota Metodológica: Parâmetros Populacionais vs. Estatísticas Amostrais

Em estatística descritiva, a diferença básica entre o alfabeto comum (latino) e o alfabeto grego serve para diferenciar as propriedades de uma amostra das propriedades de uma população inteira. A regra geral funciona assim:

• Alfabeto Grego: Parâmetros Populacionais

As letras gregas são usadas para representar **parâmetros**, que são os valores reais e fixos de uma população inteira (o grupo completo que você quer estudar).

- μ (Mi): Média da população.
- σ (Sigma minúsculo): Desvio padrão da população.
- σ^2 : Variância da população.
- N : Tamanho total da população.

• Alfabeto Latino (Comum): Estatísticas Amostras

As letras do nosso alfabeto comum são usadas para representar **estatísticas** (ou estimadores), que são os valores calculados a partir de uma **amostra** (um subgrupo extraído da população).

- $\bar{x}$ (X-barra): Média da amostra.
- s (ou sd): Desvio padrão da amostra.
- s^2 : Variância da amostra.
- n : Tamanho da amostra.

Resumo Visual

Conceito	População (Grupo Todo)	Amostra (Parte do Grupo)
Tipo de Dado	Parâmetro (Fixo/Real)	Estatística (Estimativa)
Alfabeto	Grego	Latino (Comum)
Média	μ	$\bar{x}$
Desvio Padrão	σ	s
Variância	σ^2	s^2
Tamanho	N	n

Essa distinção é fundamental porque, na maioria das vezes, não conseguimos coletar dados de toda a população. Usamos então as letras latinas ($\bar{x}, s$) para tentar adivinhar ou aproximar os valores reais das letras gregas (μ, σ).

Nota de Encadeamento: A inserção desta nota metodológica neste ponto do texto tem a intenção de posicionar corretamente o entendimento do leitor para a demonstração analítica subsequente, dado que as letras gregas μ (Mí) e σ (Sigma minúsculo) serão fundamentais na dedução teórica do modelo de Tukey utilizando a Curva Normal.

6.2 A Função Quantil e a Posição dos Quartis na Curva Normal

Considere a variável aleatória Z com distribuição Normal Padrão, $Z \sim \mathcal{N}(0, 1)$. A sua Função de Distribuição Acumulada (FDA) é denotada pela letra grega maiúscula $\Phi(z)$, dada pela integral da densidade $\varphi(t)$:

$$\Phi(z) = P(Z \leq z) = \int_{-\infty}^z \frac{1}{\sqrt{2\pi}} e^{-\frac{t^2}{2}} dt \quad (3)$$

Geometricamente, $\Phi(z)$ fornece a área sob a curva do sino desde $-\infty$ até o ponto z .

Para determinarmos os quartis teóricos na Normal, precisamos da **Função Quantil** (inversa da Função de Distribuição Acumulada $\Phi(z)$). Como o terceiro quartil (Q_3) acumula exatamente 75% ($p = 0,75$) da área da distribuição, buscamos z tal que:

$$\Phi(z) = 0,75 \iff z = \Phi^{-1}(0,75) \quad (4)$$

Consultando um recorte da Tabela da Normal Padrão:

z	0,00	...	0,05	0,06	0,07	0,08	0,09
...	...	...	...	...	...	...	...
0,6	0,7257	...	0,7422	0,7454	0,7486	0,7517	0,7549

Tabela 1: Trecho da Tabela Normal Padrão. A área de 0,7500 está entre $z = 0,67$ e $z = 0,68$.

Por interpolação linear exata, obtemos $z \approx 0,6745$. Padronizando para $X \sim \mathcal{N}(\mu, \sigma^2)$, temos:

- $Q_3 = \mu + 0,6745\sigma$
- $Q_1 = \mu - 0,6745\sigma$

6.3 As Cercas de Tolerância e a Aproximação para $2,7\sigma$

O comprimento da caixa do boxplot, o Intervalo Interquartilico (IQR), para uma variável normalmente distribuída é:

$$\text{IQR} = Q_3 - Q_1 = (\mu + 0,6745\sigma) - (\mu - 0,6745\sigma) = 1,3490\sigma \quad (5)$$

Aplicando a regra de Tukey ($1,5 \times \text{IQR}$) para a Cerca Superior:

$$\begin{aligned} \text{Cerca Superior} &= Q_3 + 1,5 \times \text{IQR} \\ &= (\mu + 0,6745\sigma) + 1,5 \times (1,3490\sigma) \\ &= \mu + 2,698\sigma \approx \mu + 2,7\sigma \end{aligned} \quad (6)$$

6.4 Comparação: Tukey versus Gauss

A tabela abaixo compara a probabilidade de um ponto ser classificado como *outlier* em uma distribuição Normal perfeita:

Critério	Limite nos Dados	$P(\text{Dentro})$	Prob. Outlier
Regra de Gauss (3σ)	$\mu \pm 3,000\sigma$	99,73%	0,27% (1 em 370)
Boxplot de Tukey (1,5)	$\mu \pm 2,698\sigma$	99,30%	0,70% (1 em 143)

Tabela 2: Comparativo das áreas de cauda (Falsos Positivos).

A genialidade do cálculo mental: Para que o corte de Tukey fosse exatamente em 3σ , o multiplicador deveria ser cerca de 1,72. No entanto, Tukey concebeu a ferramenta na era pré-computacional (1970). Multiplicar por 1,5 é trivial ($\text{IQR} + \text{IQR}/2$), unindo rigor analítico e simplicidade metodológica com perfeição.

7 Declaração de Transparência no Uso de IA Generativa

DECLARAÇÃO DE USO DE FERRAMENTAS DE INTELIGÊNCIA ARTIFICIAL GENERATIVA

(Em conformidade com as diretrizes de integridade da CAPES e alinhada ao Art. 9º da Portaria CNPq nº 2.664/2026)

Declaro que utilizei ferramentas de Inteligência Artificial Generativa do ecossistema Google Gemini (Gemini 2.5 Pro, Gemini 3.1 Pro via interface de linha de comando Anti-gravity CLI e Gemini Notebook) exclusivamente como apoio instrumental para concepção didática, estruturação lógica do tempo de apresentação, geração de templates computacionais em Python/Plotly e formatação L^AT_EX das expressões analíticas.

Todos os cálculos, conceitos matemáticos, análises descritivas e interpretações foram revisados, verificados e validados pelo autor humano, que assume responsabilidade científica e autoral integral pelo trabalho.

8 Referências Bibliográficas

- BARBETTA, Pedro Alberto. **Estatística aplicada às ciências sociais**. 8. ed. Florianópolis: Editora da UFSC, 2012.
- BUSSAB, Wilton de Oliveira; MORETTIN, Pedro Alberto. **Estatística básica**. 9. ed. São Paulo: Saraiva, 2017.
- HOAGLIN, David C.; IGLEWICZ, Boris; TUKEY, John W. Performance of alternative principles of the rule for identification of outliers. **Journal of the American Statistical Association**, v. 81, n. 396, p. 991-999, 1986.
- MORGADO, Augusto César de Oliveira *et al.* **Análise combinatória e probabilidade**. 10. ed. Rio de Janeiro: SBM, 2016. (Coleção do Professor de Matemática).
- PROVENZA, Marcello Montillo. **Probabilidade e Estatística: notas de aula**. Rio de Janeiro: Universidade do Estado do Rio de Janeiro (UERJ) / PROFMAT, 2026. 6 fascículos em PDF. Material didático de circulação interna.
- TUKEY, John Wilder. **Exploratory data analysis**. Reading, MA: Addison-Wesley, 1977.